

Tarea - Ejercicio Empírico 3

Profesor: Mauricio Tejada - Estudiante: Matías Vicuña

26/09/2022

Parte 1

Gráfico 1.1





Gráfico 1.2



Parte 2

Modelos Autoregresivos

Ahora presentamos el modelo Autoregresivo (AR), la cual en el modelo autoregresivo de p rezagos se define como:

$$AR(p) = y_t = \beta_0 + \beta_1 y_{t-1} + \beta_2 y_{t-2} + \dots + \beta_p y_{t-p} + u_t$$

Ahora, construimos los modelos desde el $AR(1)$ al $AR(8)$:

Table 1: Modelo $AR(1)$, $AR(2)$ y $AR(3)$

	<i>Dependent variable:</i>		
	AR(1)	dif.lipm AR(2)	AR(3)
L(dif.lipm)	-0.482*** (0.069)		
L(dif.lipm, 1:2)1		-0.609*** (0.076)	
L(dif.lipm, 1:2)2		-0.284*** (0.076)	
L(dif.lipm, 1:3)1			-0.668*** (0.079)
L(dif.lipm, 1:3)2			-0.413*** (0.089)
L(dif.lipm, 1:3)3			-0.208*** (0.078)
Constant	0.002 (0.004)	0.002 (0.004)	0.002 (0.004)
Adjusted R ²	0.230	0.282	0.305
Residual Std. Error	0.052 (df = 159)	0.049 (df = 157)	0.049 (df = 155)
F Statistic	48.857*** (df = 1; 159)	32.149*** (df = 2; 157)	24.135*** (df = 3; 155)

Note:

*p<0.1; **p<0.05; ***p<0.01

Table 2: Modelo AR(4), AR(5) y AR(6)

	<i>Dependent variable:</i>		
	AR(4)	dif.lipm AR(5)	AR(6)
L(dif.lipm, 1:4)1	−0.757*** (0.074)		
L(dif.lipm, 1:4)2	−0.586*** (0.088)		
L(dif.lipm, 1:4)3	−0.480*** (0.088)		
L(dif.lipm, 1:4)4	−0.404*** (0.074)		
L(dif.lipm, 1:5)1		−0.705*** (0.081)	
L(dif.lipm, 1:5)2		−0.524*** (0.096)	
L(dif.lipm, 1:5)3		−0.407*** (0.100)	
L(dif.lipm, 1:5)4		−0.306*** (0.096)	
L(dif.lipm, 1:5)5		0.132 (0.082)	
L(dif.lipm, 1:6)1			−0.654*** (0.075)
L(dif.lipm, 1:6)2			−0.642*** (0.092)
L(dif.lipm, 1:6)3			−0.566*** (0.097)
L(dif.lipm, 1:6)4			−0.514*** (0.097)
L(dif.lipm, 1:6)5			−0.143 (0.092)
L(dif.lipm, 1:6)6			−0.402*** (0.077)
Constant	0.003 (0.004)	0.003 (0.004)	0.004 (0.003)
Adjusted R ²	0.414	0.420	0.505
Residual Std. Error	0.045 (df = 153)	0.045 (df = 151)	0.041 (df = 149)
F Statistic	28.689*** (df = 4; 153)	23.586*** (df = 5; 151)	27.387*** (df = 6; 149)

Note:

*p<0.1; **p<0.05; ***p<0.01

Table 3: Modelo AR(7) y AR(8)

	<i>Dependent variable:</i>	
	AR(7)	AR(8)
L(dif.lipm, 1:7)1	−0.639*** (0.083)	
L(dif.lipm, 1:7)2	−0.636*** (0.093)	
L(dif.lipm, 1:7)3	−0.546*** (0.106)	
L(dif.lipm, 1:7)4	−0.491*** (0.109)	
L(dif.lipm, 1:7)5	−0.117 (0.107)	
L(dif.lipm, 1:7)6	−0.377*** (0.094)	
L(dif.lipm, 1:7)7	0.040 (0.085)	
L(dif.lipm, 1:8)1		−0.635*** (0.082)
L(dif.lipm, 1:8)2		−0.670*** (0.098)
L(dif.lipm, 1:8)3		−0.561*** (0.107)
L(dif.lipm, 1:8)4		−0.540*** (0.116)
L(dif.lipm, 1:8)5		−0.170 (0.116)
L(dif.lipm, 1:8)6		−0.449*** (0.108)
L(dif.lipm, 1:8)7		−0.018 (0.101)
L(dif.lipm, 1:8)8		−0.096 (0.086)
Constant	0.004 (0.003)	0.004 (0.003)
Adjusted R ²	0.501	0.507
Residual Std. Error	0.042 (df = 147)	0.041 (df = 145)
F Statistic	23.055*** (df = 7; 147)	20.675*** (df = 8; 145)

Note:

*p<0.1; **p<0.05; ***p<0.01

Finalizamos comprobando cual de los modelos se ajusta mejor, para ello usamos el método *AIC*, que se determina con la siguiente formula:

$$AIC(p) = \ln\left(\frac{SRC(p)}{T}\right) + (p+1)\frac{2}{T}$$

```
##      Models          AIC
## 1  AR(1) -952.649589727125
## 2  AR(2) -959.969749553088
## 3  AR(3) -958.090672250325
## 4  AR(4) -976.911021480577
## 5  AR(5) -970.489231730488
## 6  AR(6) -987.631945393241
## 7  AR(7) -978.475887947625
## 8  AR(8) -972.183619686683
```

Viendo el resultado que nos arroja AIC, concluimos que la afirmación es correcta, dado que el valor mínimo se presenta en el modelo de AR(6).

Parte 3

```
## Linear hypothesis test
##
## Hypothesis:
## L(dif.lipm,6)5 = 0
## L(dif.lipm,6)6 = 0
##
## Model 1: restricted model
## Model 2: dif.lipm ~ L(dif.lipm, 1:6)
##
##      Res.Df      RSS Df Sum of Sq      F      Pr(>F)
## 1      151 0.30584
## 2      149 0.25389   2   0.051956 15.246 9.465e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Respuesta: Según lo que nos entregó la hipótesis, se rechaza la hipótesis nula y comprobamos que el mejor modelo es el AR(6).

Parte 4

Generamos la predicción usando la función *predict*, en dónde para las predicciones j periodos adelante se determina de la siguiente forma:

$$y_{T+j|T} = \phi_0(1 + \phi_1 + \phi_1^2 + \dots + \phi_1^{j-1}) + \phi_1^j y_T$$

```
##      fecha      prediccion
## 1 Aug 2022  0.059692019433705
## 2 Sep 2022 -0.0798415203958785
## 3 Oct 2022  0.0793682722999781
## 4 Nov 2022 -0.0392038871163718
## 5 Dec 2022  0.00885125160621689
```

Parte 5

Usando los valores que obtuvimos de la predicción en la parte anterior, realizamos unos calculos para lograr conseguir el índice de diciembre de 2022.

IPM_{dic22} :

```
## [1] 100.4552
```

Parte 6

Luego de hacer todos los calculos anteriores y definir el índice del año 2022, usamos el método *ar* y *forecast* para desarrollarlo, mostraré los códigos a usar y desarrollar.

```
##### Parte 6 #####
```

```
reg <- ar(dif.lipm, order.max = 8, aic = TRUE)
reg$aic
```

```
##           0           1           2           3           4           5           6
## 102.476060  61.676525  49.649969  44.320724  19.912245  20.258979  0.000000
##           7           8
##   1.955271   3.128444
```

```
reg_final <- ar(dif.lipm, order.max = 6)
resultados <- forecast(reg_final, h = 5, level = 0.95)
resultados
```

```
##           Point Forecast           Lo 95           Hi 95
## Aug 2022    0.059692019 -0.02301321  0.14239725
## Sep 2022   -0.079841520 -0.18021025  0.02052721
## Oct 2022    0.079368272 -0.02200003  0.18073657
## Nov 2022   -0.039203887 -0.14057269  0.06216492
## Dec 2022    0.008851252 -0.09251755  0.11022006
```

```
# Respuesta: Se llega a los mismo resultados anteriormente conseguidos en el apartado 4, comprobando su
```